

Universidade de Brasília
Instituto de Ciências Exatas
Departamento de Ciência da Computação

HySAIL: título a definir

Autor HySAIL

Dissertação apresentada como requisito parcial para qualificação do
Mestrado Profissional em Computação Aplicada

Orientador
Prof. Dr. Orientador a definir

Brasília
2026



Universidade de Brasília
Instituto de Ciências Exatas
Departamento de Ciência da Computação

HySAIL: título a definir

Autor HySAIL

Dissertação apresentada como requisito parcial para qualificação do
Mestrado Profissional em Computação Aplicada

Prof. Dr. Orientador a definir (Orientador)
CIC/UnB

Prof. Dr. Avaliador a definir
Instituição a definir

Prof. Dr. Avaliador a definir
Instituição a definir

Prof.a Dr.a Coordenação a definir
Coordenadora do Programa de Pós-graduação em Computação Aplicada

Brasília, 14 de outubro de 2026

Resumo

Palavras-chave: palavras-chave a definir

Abstract

Keywords: keywords to be defined

Contents

1 Apresentação **1**

1.1 Objetivos 4

1.2 Contribuições Esperadas 4

1.3 Organização do Trabalho 4

2 Fundamentação Teórica e Trabalhos Relacionados **5**

2.1 Conceitos Fundamentais 5

2.2 Corpos finitos e corpo de Galois 5

2.2.1 Exemplo de representação polinomial 5

2.3 Divisão polinomial em GF(2) 6

2.3.1 Exemplo de divisão passo a passo 6

2.3.2 HySAIL e Codificação de Blocos 7

2.3.3 LT Codes 7

2.3.4 RaptorQ Codes 8

3 Metodologia de Pesquisa **9**

4 Proposta **10**

5 Implementação **11**

6 Resultados **12**

7 Conclusão **13**

Referências **14**

Acronyms

EB Exabyte.

PB Petabyte.

ZB Zettabyte.

Chapter 1

Apresentação

Desde a proposta do HySAIL, em 2013, o cenário tecnológico passou por transformações significativas. A expansão da computação em nuvem, dos dispositivos móveis, da Internet das Coisas e dos serviços digitais alterou a forma como os dados são produzidos, armazenados, processados e compartilhados. Nesse contexto, abordagens concebidas naquele período devem ser analisadas à luz das novas demandas tecnológicas, dos diferentes ambientes de processamento e das atuais expectativas de segurança e privacidade.

O crescimento da produção de dados está ligado à digitalização de atividades cotidianas e científicas. Interações em redes sociais, transações comerciais, sensores conectados, serviços de streaming e experimentos científicos geram registros em diferentes formatos e de forma contínua. Para dimensionar essa produção, é importante distinguir entre dados publicados ou coletados, tráfego transmitido e dados acumulados em armazenamento: são métricas relacionadas, mas não equivalentes.

O repositório *Amazon Simple Storage Service* (S3) registrava mais de 100 trilhões de objetos acumulados até 2021, totalizando cerca de *500 EB* armazenados. O tráfego de vídeos consumidos na Netflix gerou aproximadamente *51,1 EB* em 2021[1], enquanto as trocas globais de e-mails e spam movimentaram cerca de *5,7 EB* no mesmo período. O volume anual de conteúdos criados no YouTube atinge cerca de *263 PB*, ao passo que o compartilhamento de imagens no Facebook e no Instagram representa *252 PB* e *68 PB*, respectivamente [1].

Nos experimentos de física de altas energias do CERN, os sistemas eletrônicos de leitura do *Large Hadron Collider* (LHC) geraram cerca de *40 ZB* de dados brutos de colisão em 2018[1]. Como é inviável armazenar todo esse volume, sistemas de seleção (*triggers*) filtram o fluxo para gravar cerca de *160 PB* por ano (∼240 PB, incluindo simulações de Monte Carlo)[1]. Com o projeto *High-Luminosity LHC* (HL-LHC), prevê-se o registro de *800 PB* de novos dados por ano a partir de 2026[1]. Além disso, a rede de distribuição *Worldwide LHC Computing Grid* (WLCG) atingiu uma vazão de 60 GB/s,

movimentando cerca de *1,9 EB* por ano[1].

O crescimento desses fluxos também favorece a expansão de sistemas de inteligência artificial (IA), que dependem de dados para treinamento, validação e operação. Segundo o *AI Index Report 2025*, a proporção de organizações que declararam utilizar IA em pelo menos uma função empresarial passou de 55% em 2023 para 78% em 2024. A adoção dessas tecnologias amplia as possibilidades de análise e automação, mas torna indispensáveis mecanismos de governança, controle de acesso e proteção de dados pessoais, a fim de reduzir riscos à privacidade, à segurança e à confiabilidade dos sistemas e de seus resultados.

O volume de dados utilizado para treinar modelos de IA de ponta aumentou cerca de *30.000 vezes desde 2008*[2]. Desde 2014, o volume de processamento computacional aumentou 350.000 vezes. Como exemplo, o modelo GPT-4 exigiu cerca de 4,9 trilhões de pontos de dados para seu treinamento. Projeta-se que, até 2035, o tráfego de inferência de IA passe a responder por 25% de todo o tráfego de rede mundial.

Nesse cenário de grande produção e consumo de dados, soluções estabelecidas continuam a fundamentar tecnologias atuais. Entre elas, destaca-se o armazenamento em nuvem, um modelo de computação que permite guardar, gerenciar e acessar dados remotamente por meio da Internet, em vez de mantê-los exclusivamente em dispositivos físicos ou servidores locais [2]. Entre suas vantagens, destacam-se:

- *Escalabilidade e Elasticidade:* permite expandir ou reduzir a capacidade de armazenamento de forma dinâmica à medida que o volume de dados cresce, sem a necessidade de gerenciar diretamente o hardware subjacente [2].
- *Redução de Custos:* minimiza despesas com infraestrutura local, manutenção física e aquisição de servidores próprios [3].
- *Capacidade de Acesso Global:* os dados armazenados em centros de dados distribuídos podem ser acessados de qualquer localidade com suporte a conexões de alta velocidade[3].
- *Suporte a Múltiplas Arquiteturas de Dados:* abrange desde o armazenamento de objetos (como Amazon S3) até sistemas de arquivos distribuídos (como o Hadoop Distributed File System – HDFS) e Data Lakes, capazes de armazenar grandes volumes de dados brutos e estruturados [2].

Diante desse cenário de grande volume de dados, persistem diversos problemas relacionados à sua segurança, tais como:

- *Falhas de Anonimização e Ataques de Reidentificação:* dados aparentemente anonimizados por remoção de identificadores diretos permanecem vulneráveis a ataques

de vinculação (*linkage attacks*)[4]. Estudos demonstram que apenas quatro pontos espaço-temporais em bases de mobilidade ou histórico de compras são suficientes para reidentificar entre 90% e 95% dos indivíduos quando cruzados com outras fontes [4].

- *Ameaça do Aprendizado de Máquina e Mineração de Dados:* o avanço dos algoritmos de *data mining* e *machine learning* permite inferir e extrair conhecimentos sensíveis não autorizados a partir da correlação de bases de dados aparentemente inofensivas.
- *Limitações das Técnicas Tradicionais de Agrupamento:* modelos clássicos de privacidade em bancos de dados, como k-*anonymity*, são suscetíveis a ataques de homogeneidade e de conhecimento prévio (*background knowledge attacks*)[4]. Extensões como l-*diversity* e t-*closeness* foram criadas para mitigar essas falhas, aumentando a variação de atributos sensíveis e limitando o ganho de informação por invasores[4].
- *Gargalos Criptográficos e Ataques de Informação Lateral:* a criptografia convencional enfrenta barreiras de escalabilidade e alto custo computacional em ambientes de Big Data e dispositivos móveis[4]. Soluções como *Criptografia Baseada em Atributos (ABE)* e *criptografia pesquisável* buscam integrar o controle de acesso e a busca em dados cifrados[4]. Além disso, a criptografia do conteúdo não impede ataques de análise de tráfego (*side information attacks*), que identificam padrões e "pegadas" (*fingerprints*) de navegação[4].
- *Vulnerabilidades em Fluxo (*Streaming*) e Armazenamento:* dados em transmissão contínua (*streaming*) estão sujeitos a vazamentos na origem, antes da cifragem; à interceptação e à adulteração durante a transferência pela rede; e à perda de integridade ou confiabilidade nos repositórios de armazenamento[5].
- *Ameaças Cibernéticas a Infraestruturas Críticas:* redes de sensores IoT, ambientes industriais e *Data Lakes* tornaram-se alvos diretos de programas maliciosos, intrusões, *phishing*, e-mails enganosos e ataques de negação de serviço (DDoS)[6].
- *Dilemas Éticos, Legais e de Perfilamento:* a coleta massiva levanta questionamentos sobre o consentimento implícito e o explícito [7]. O uso de análise preditiva para perfilamento (*profiling*) traz riscos de discriminação e decisões injustas[20], exigindo conformidade com regulamentações, como a GDPR, e salvaguardas como o "direito ao esquecimento"[4].

Portanto, embora o cenário tecnológico tenha evoluído, permanece necessária a adoção de ferramentas que restrinjam o acesso indevido a dados que precisam ser protegidos.

1.1 Objetivos

A princípio, a fundamentação de HySAIL é dependente de Online Codes para a geração de blocos que são distribuídos. Considerando novas otimizações aplicadas em RaptorQ Codes [8], o presente trabalho visa explorar a utilização do mesmo para o processo de codificação e decodificação de blocos.

Após a implementação e a avaliação dessas mudanças, serão realizadas comparações com soluções adotadas anteriormente, a fim de identificar os ganhos proporcionados pelo novo modelo.

1.2 Contribuições Esperadas

Ao final deste trabalho, espera-se que o modelo proposto para codificação e decodificação de blocos utilizando RaptorQ Codes apresente melhorias em termos de eficiência, segurança e robustez em comparação com as soluções baseadas em Online Codes e que exista prova matemática que admita seu uso.

Além disso, espera-se que as contribuições deste estudo forneçam subsídios para a adoção de técnicas avançadas de codificação em cenários de Big Data e ambientes distribuídos.

1.3 Organização do Trabalho

O presente trabalho está organizado da seguinte forma:

- No Capítulo 2, são apresentados os conceitos fundamentais e o estado da arte relacionado à codificação de blocos e RaptorQ Codes.
- O Capítulo 3 descreve a metodologia adotada para a implementação do modelo proposto.
- No Capítulo 4, são apresentados os resultados obtidos e a análise comparativa com soluções baseadas em Online Codes.
- Finalmente, o Capítulo 5 apresenta as conclusões e as perspectivas para trabalhos futuros.

Chapter 2

Fundamentação Teórica e Trabalhos Relacionados

2.1 Conceitos Fundamentais

Antes de detalhar o modelo proposto, é importante compreender alguns conceitos matemáticos relacionados à codificação de blocos. Por fim, para que possamos compreender a nova abordagem adotada, é necessário revisar o funcionamento de HySAIL, LT Codes e RaptorQ Codes.

2.2 Corpos finitos e corpo de Galois

O corpo de Galois é uma estrutura algébrica que define operações e suas propriedades sobre um conjunto finito de elementos. No contexto do HySail, destacam-se o corpo $GF(2)$ e suas extensões $GF(2^n)$, que permitem representar e manipular dados binários por meio de operações matematicamente bem definidas.

Em $GF(2)$, os únicos elementos são 0 e 1, e a soma segue a mesma lógica da operação XOR, ou seja, o resultado é 0 quando os operandos são iguais e 1 quando são diferentes. Assim, $1 + 1 = 0$ e $1 + 0 = 1$. As extensões $GF(2^n)$, por sua vez, permitem operar sob elementos representados por combinações de n coeficientes binários.

2.2.1 Exemplo de representação polinomial

Considere o vetor binário 1011. Adotando a convenção usada pelo projeto, em que a primeira posição do vetor representa o termo constante, o bloco é lido em três passos:

1. o primeiro coeficiente vale 1 e representa 1;

2. o segundo coeficiente vale 0 e representa $0x$;

3. os coeficientes seguintes valem 1 e 1, representando x^2 e x^3.

Assim, o bloco passa a ser escrito como $1 + x^2 + x^3$.

2.3 Divisão polinomial em $GF(2)$

A divisão polinomial em $GF(2)$ segue a mesma lógica estrutural da divisão entre inteiros, mas com uma diferença importante: como os coeficientes pertencem a um corpo binário, subtração e soma são equivalentes a XOR. Portanto, ao somar dois termos iguais, eles se anulam: $x^k + x^k = 0$.

Dado um dividendo $m(x)$ e um divisor $p(x)$, procura-se obter um quociente $q(x)$ e um resto $r(x)$ tais que

$$m(x) = q(x) \cdot p(x) + r(x),$$

com $\deg(r) < \deg(p)$.

O procedimento é repetido enquanto o resto parcial tiver grau maior ou igual ao grau do divisor. Em cada iteração, divide-se o termo de maior grau do resto parcial pelo termo de maior grau do divisor. O resultado é o próximo termo do quociente. Em seguida, esse termo multiplica o divisor, e aplica-se XOR entre o produto e o resto parcial. Essa operação elimina o termo de maior grau, reduzindo o grau do novo resto.

2.3.1 Exemplo de divisão passo a passo

Seja $m(x) = x^3 + x + 1$ o dividendo e $p(x) = x^2 + 1$ o divisor. Inicialmente, o resto parcial é o próprio dividendo:

$$r_0(x) = x^3 + x + 1.$$

1. O termo de maior grau de $r_0(x)$ é x^3 e o de $p(x)$ é x^2. Logo, o próximo termo do quociente é $x^3/x^2 = x$.

2. Multiplica-se esse termo pelo divisor: $x \cdot p(x) = x(x^2 + 1) = x^3 + x$.

3. Aplica-se XOR entre o resto parcial e o produto:

$$r_1(x) = (x^3 + x + 1) + (x^3 + x) = 1.$$

Os termos x^3 e x se anulam porque cada um aparece duas vezes.

4. Como $\deg(1) = 0$ é menor que $\deg(p) = 2$, a divisão termina. O quociente é $q(x) = x$ e o resto é $r(x) = 1$.

Substituindo o quociente e o resto obtidos na identidade da divisão, verifica-se que

$$x^3 + x + 1 = x(x^2 + 1) + 1.$$

Pela convenção em que o primeiro bit representa o coeficiente do termo constante, o quociente $q(x) = x$ tem representação binária 01, e o resto $r(x) = 1$ tem representação binária 1. Caso o resto seja armazenado com dois bits, que é o número de coeficientes de grau menor que o divisor de grau 2, sua representação é 10.

2.3.2 HySAIL e Codificação de Blocos

Empty

2.3.3 LT Codes

LtCodes pertencem à classe dos códigos fountain digitais (digital fountain codes), baseados na transformada de Luby, introduzidos por Michael Luby em 2002 [9]. Esses códigos são construídos randomicamente durante o processo de codificação, onde cada símbolo codificado é gerado através da combinação linear de um número variável de símbolos de origem.

A distribuição de grau (quantidade de símbolos que serão combinados) é otimizada para minimizar o número de símbolos necessários para a recuperação completa dos dados, adotando a distribuição de grau de Soliton robusta (robust Soliton distribution), isto é, a distribuição de Soliton ideal acrescida de um termo corretivo para elevar a probabilidade de decodificação completa com baixo overhead [10].

Robust Soliton Distribution

Nos *LtCodes*, a escolha do grau de cada símbolo codificado (bloco de bytes do arquivo, usado como unidade de codificação e decodificação) é controlada pela *robust Soliton distribution*, proposta para melhorar o desempenho de decodificação em tamanho finito [9, 11]. A construção parte de duas distribuições: a distribuição de Soliton ideal $\rho(d)$ e um termo corretivo $\tau(d)$.

Para k símbolos de origem, a distribuição ideal é dada por:

$$\rho(d) = \begin{cases} \frac{1}{k}, & d = 1 \\ \frac{1}{d(d-1)}, & d = 2, \ldots, k \end{cases} \tag{2.1}$$

Define-se $R = c \ln\left(\frac{k}{\delta}\right) \sqrt{k}$, com $c > 0$ e $\delta \in (0, 1)$. O termo corretivo é:

$$\tau(d) = \begin{cases} \frac{R}{dk}, & d = 1, \ldots, \left\lfloor \frac{k}{R} \right\rfloor - 1 \\ \frac{R \ln\left(\frac{R}{\delta}\right)}{k}, & d = \left\lfloor \frac{k}{R} \right\rfloor \\ 0, & d > \left\lfloor \frac{k}{R} \right\rfloor \end{cases} \tag{2.2}$$

A robust Soliton distribution final é a normalização:

$$\mu(d) = \frac{\rho(d) + \tau(d)}{Z}, \quad Z = \sum_{i=1}^{k} (\rho(i) + \tau(i)) \tag{2.3}$$

Essa formulação aumenta a probabilidade de existência de símbolos de grau baixo durante a decodificação por *belief propagation*, reduzindo o risco de estagnação do processo e mantendo baixo overhead de recepção [9, 12].

Os LtCodes utilizam operações XOR iterativas em corpos finitos (típicamente GF(2) para aplicações binárias). Seja $\mathbf{d} = (d_1, d_2, \ldots, d_k)$ o vetor contendo os k símbolos de origem, o processo de codificação gera n símbolos codificados $\mathbf{c} = (c_1, c_2, \ldots, c_n)$ conforme:

$$c_i = \bigoplus_{j \in S_i} d_j \tag{2.4}$$

onde $\bigoplus$ denota a operação XOR (ou soma em GF(2)), e S_i é um subconjunto de índices selecionados randomicamente de acordo com uma distribuição de grau Soliton. O grau (quantidade de índices em S_i, isto é, quantos símbolos originais serão combinados) $|S_i|$ segue uma distribuição de probabilidade específica $\rho(d)$:

$$\rho(d) = \begin{cases} 1/k & \text{se } d = 1 \\ 1/(d(d-1)) & \text{se } d = 2, 3, \ldots, k \end{cases} \tag{2.5}$$

A decodificação procede iterativamente, identificando símbolos codificados com grau 1 (que correspondem diretamente a símbolos de origem) e propagando a informação até recuperar todos os k símbolos originais. Sendo este processo o *belief propagation*.

2.3.4 RaptorQ Codes

Empty

Chapter 3

Metodologia de Pesquisa

Chapter 4

Proposta

Chapter 5

Implementação

Chapter 6

Resultados

Chapter 7

Conclusão

Referências

[1] Luca Clissa, Mario Lassnig, Lorenzo Rinaldi: *How big is big data? a comprehensive survey of data production, storage, and streaming in science and industry.* Big Data and AI in High Energy Physics, 6(9), 2023. https://www.frontiersin.org/journals/big-data/articles/10.3389/fdata.2023.1271639/full. 1, 2

[2] Begen, Ali C., Thomas Stockhammer, and Colin Perkins: *Energy and ai.* Technical report, INTERNATIONAL ENERGY AGENCY, 2025. https://www.iea.org/. 2

[3] Amaral, Dino Macedo: *Hy-SAIL: Uma nova abordagem para distribuição e armazenamento de informações em ambientes de computação em nuvem.* PhD thesis, Universidade de Brasília, 2013. 2

[4] Yu, Shui: *Big privacy: Challenges and opportunities of privacy study in the age of big data.* IEEE Access, 4:2751–2763, 2016. 3

[5] Zhao, Xiaoyan, Conghui Zhang, and Shaopeng Guan: *A data lake-based security transmission and storage scheme for streaming big data.* Cluster Computing, 27(4):4741–4755, Jul 2024, ISSN 1573-7543. https://doi.org/10.1007/s10586-023-04201-9. 3

[6] Hakami, Tahani Ali, Yasser M. Alginahi, and Omar Sabri: *Exploring the evolution of big data technologies: A systematic literature review of trends, challenges, and future directions.* Future Internet, 17(9), 2025, ISSN 1999-5903. https://www.mdpi.com/1999-5903/17/9/427. 3

[7] Villamar-Torres, Ronald Oswaldo, Verónica Cristina Andrade Yucailla, Karen Rafaela Mayorga Morejon, Héctor Adonis Almeida Reyes, and Seyed Mehdi Jazayeri: *An overview to the new era in efficient crop management: Artificial intelligence, machine learning, big data, bioinformatics, metagenomics and precision agriculture.* Journal of Animal and Plant Sciences, 35(3):638–659, June 2025, ISSN 1018-7081. https://thejaps.org.pk/AbstractView.aspx?mid=2024-japs-1928. 3

[8] Ko, Dongyub, Kijong Koo, and Do Young Kim: *Reducing the decoding complexity of raptorq codes for delay sensitive applications using a simplified and scaled-down matrix.* AEU-INTERNATIONAL JOURNAL OF ELECTRONICS AND COMMUNICATIONS, 70(9):1356–1360, 2016, ISSN 1434-8411. 4

[9] Luby, Michael: *Lt codes.* In *Proceedings of the 43rd Symposium on Foundations of Computer Science (FOCS)*, pages 271–280. IEEE Computer Society, 2002. 7, 8

[10] Shokrollahi, Amin: *Raptor codes.* IEEE Transactions on Information Theory, 52(6):2551–2567, 2006. 7

[11] Karp, Richard, Michael Luby, and Amin Shokrollahi: *Finite length analysis of lt codes.* In *Proceedings of the 2004 IEEE International Symposium on Information Theory (ISIT)*, page 39. IEEE, 2004. 7

[12] Hyytia, Esa, Vesa Tirronen, and Jorma Virtamo: *On the degree distribution of lt codes with unequal error protection.* IEEE Communications Letters, 11(8):642–644, 2007. 8