

Universidade de Brasília
Instituto de Ciências Exatas
Departamento de Ciência da Computação

HySAIL: título a definir

Autor HySAIL

Dissertação apresentada como requisito parcial para qualificação do
Mestrado Profissional em Computação Aplicada

Orientador
Prof. Dr. Orientador a definir

Brasília
2026



Universidade de Brasília
Instituto de Ciências Exatas
Departamento de Ciência da Computação

HySAIL: título a definir

Autor HySAIL

Dissertação apresentada como requisito parcial para qualificação do
Mestrado Profissional em Computação Aplicada

Prof. Dr. Orientador a definir (Orientador)
CIC/UnB

Prof. Dr. Avaliador a definir
Instituição a definir

Prof. Dr. Avaliador a definir
Instituição a definir

Prof.a Dr.a Coordenação a definir
Coordenadora do Programa de Pós-graduação em Computação Aplicada

Brasília, 14 de outubro de 2026

Resumo

Palavras-chave: palavras-chave a definir

Abstract

Keywords: keywords to be defined

Contents

1 Apresentação **1**

1.1 Objetivos 4

2 HySAIL **5**

3 Trabalhos Relacionados **6**

4 Metodologia **7**

5 Resultados **8**

Referências **9**

Acronyms

EB Exabyte.

PB Petabyte.

ZB Zettabyte.

Chapter 1

Apresentação

Desde a proposta do HySAIL, em 2013, o cenário tecnológico passou por transformações significativas. A expansão da computação em nuvem, dos dispositivos móveis, da Internet das Coisas e dos serviços digitais alterou a forma como os dados são produzidos, armazenados, processados e compartilhados. Nesse contexto, abordagens concebidas naquele período devem ser analisadas à luz das novas demandas tecnológicas, dos diferentes ambientes de processamento e das atuais expectativas de segurança e privacidade.

O crescimento da produção de dados está ligado à digitalização de atividades cotidianas e científicas. Interações em redes sociais, transações comerciais, sensores conectados, serviços de streaming e experimentos científicos geram registros em diferentes formatos e de forma contínua. Para dimensionar essa produção, é importante distinguir entre dados publicados ou coletados, tráfego transmitido e dados acumulados em armazenamento: são métricas relacionadas, mas não equivalentes.

O repositório *Amazon Simple Storage Service* (S3) registrava mais de 100 trilhões de objetos acumulados até 2021, totalizando cerca de *500 EB* armazenados. O tráfego de vídeos consumidos na Netflix gerou aproximadamente *51,1 EB* em 2021[1], enquanto as trocas globais de e-mails e spam movimentaram cerca de *5,7 EB* no mesmo período. O volume anual de conteúdos criados no YouTube atinge cerca de *263 PB*, ao passo que o compartilhamento de imagens no Facebook e no Instagram representa *252 PB* e *68 PB*, respectivamente [1].

Nos experimentos de física de altas energias do CERN, os sistemas eletrônicos de leitura do *Large Hadron Collider* (LHC) geraram cerca de *40 ZB* de dados brutos de colisão em 2018[1]. Como é inviável armazenar todo esse volume, sistemas de seleção (*triggers*) filtram o fluxo para gravar cerca de *160 PB* por ano (∼240 PB, incluindo simulações de Monte Carlo)[1]. Com o projeto *High-Luminosity LHC* (HL-LHC), prevê-se o registro de *800 PB* de novos dados por ano a partir de 2026[1]. Além disso, a rede de distribuição *Worldwide LHC Computing Grid* (WLCG) atingiu uma vazão de 60 GB/s,

movimentando cerca de *1,9 EB* por ano[1].

O crescimento desses fluxos também favorece a expansão de sistemas de inteligência artificial (IA), que dependem de dados para treinamento, validação e operação. Segundo o *AI Index Report 2025*, a proporção de organizações que declararam utilizar IA em pelo menos uma função empresarial passou de 55% em 2023 para 78% em 2024. A adoção dessas tecnologias amplia as possibilidades de análise e automação, mas torna indispensáveis mecanismos de governança, controle de acesso e proteção de dados pessoais, a fim de reduzir riscos à privacidade, à segurança e à confiabilidade dos sistemas e de seus resultados.

O volume de dados utilizado para treinar modelos de IA de ponta aumentou cerca de *30.000 vezes desde 2008*[2]. Desde 2014, o volume de processamento computacional aumentou 350.000 vezes. Como exemplo, o modelo GPT-4 exigiu cerca de 4,9 trilhões de pontos de dados para seu treinamento. Projeta-se que, até 2035, o tráfego de inferência de IA passe a responder por 25% de todo o tráfego de rede mundial.

Nesse cenário de grande produção e consumo de dados, soluções estabelecidas continuam a fundamentar tecnologias atuais. Entre elas, destaca-se o armazenamento em nuvem, um modelo de computação que permite guardar, gerenciar e acessar dados remotamente por meio da Internet, em vez de mantê-los exclusivamente em dispositivos físicos ou servidores locais [2]. Entre suas vantagens, destacam-se:

- *Escalabilidade e Elasticidade:* permite expandir ou reduzir a capacidade de armazenamento de forma dinâmica à medida que o volume de dados cresce, sem a necessidade de gerenciar diretamente o hardware subjacente [2].
- *Redução de Custos:* minimiza despesas com infraestrutura local, manutenção física e aquisição de servidores próprios [3].
- *Capacidade de Acesso Global:* os dados armazenados em centros de dados distribuídos podem ser acessados de qualquer localidade com suporte a conexões de alta velocidade[3].
- *Suporte a Múltiplas Arquiteturas de Dados:* abrange desde o armazenamento de objetos (como Amazon S3) até sistemas de arquivos distribuídos (como o Hadoop Distributed File System – HDFS) e Data Lakes, capazes de armazenar grandes volumes de dados brutos e estruturados [2].

Diante desse cenário de grande volume de dados, persistem diversos problemas relacionados à sua segurança, tais como:

- *Falhas de Anonimização e Ataques de Reidentificação:* dados aparentemente anonimizados por remoção de identificadores diretos permanecem vulneráveis a ataques

de vinculação (*linkage attacks*)[4]. Estudos demonstram que apenas quatro pontos espaço-temporais em bases de mobilidade ou histórico de compras são suficientes para reidentificar entre 90% e 95% dos indivíduos quando cruzados com outras fontes [4].

- *Ameaça do Aprendizado de Máquina e Mineração de Dados:* o avanço dos algoritmos de *data mining* e *machine learning* permite inferir e extrair conhecimentos sensíveis não autorizados a partir da correlação de bases de dados aparentemente inofensivas.
- *Limitações das Técnicas Tradicionais de Agrupamento:* modelos clássicos de privacidade em bancos de dados, como k-*anonymity*, são suscetíveis a ataques de homogeneidade e de conhecimento prévio (*background knowledge attacks*)[4]. Extensões como l-*diversity* e t-*closeness* foram criadas para mitigar essas falhas, aumentando a variação de atributos sensíveis e limitando o ganho de informação por invasores[4].
- *Gargalos Criptográficos e Ataques de Informação Lateral:* a criptografia convencional enfrenta barreiras de escalabilidade e alto custo computacional em ambientes de Big Data e dispositivos móveis[4]. Soluções como *Criptografia Baseada em Atributos (ABE)* e *criptografia pesquisável* buscam integrar o controle de acesso e a busca em dados cifrados[4]. Além disso, a criptografia do conteúdo não impede ataques de análise de tráfego (*side information attacks*), que identificam padrões e "pegadas" (*fingerprints*) de navegação[4].
- *Vulnerabilidades em Fluxo (*Streaming*) e Armazenamento:* dados em transmissão contínua (*streaming*) estão sujeitos a vazamentos na origem, antes da cifragem; à interceptação e à adulteração durante a transferência pela rede; e à perda de integridade ou confiabilidade nos repositórios de armazenamento[5].
- *Ameaças Cibernéticas a Infraestruturas Críticas:* redes de sensores IoT, ambientes industriais e *Data Lakes* tornaram-se alvos diretos de programas maliciosos, intrusões, *phishing*, e-mails enganosos e ataques de negação de serviço (DDoS)[6].
- *Dilemas Éticos, Legais e de Perfilamento:* a coleta massiva levanta questionamentos sobre o consentimento implícito e o explícito [7]. O uso de análise preditiva para perfilamento (*profiling*) traz riscos de discriminação e decisões injustas[20], exigindo conformidade com regulamentações, como a GDPR, e salvaguardas como o "direito ao esquecimento"[4].

Portanto, embora o cenário tecnológico tenha evoluído, permanece necessária a adoção de ferramentas que restrinjam o acesso indevido a dados que precisam ser protegidos.

1.1 Objetivos

O HySAIL é um algoritmo proposto para solucionar problemas de segurança relacionados a dados estáticos. Diante disso, o objetivo deste trabalho é revisitar o algoritmo e realizar otimizações internas com base no trabalho anterior.

Após a implementação e a avaliação dessas otimizações, serão realizadas comparações com soluções adotadas anteriormente, a fim de identificar os ganhos proporcionados pelo novo modelo.

Chapter 2

HySAIL

Chapter 3

Trabalhos Relacionados

Chapter 4

Metodologia

Chapter 5

Resultados

Referências

[1] Luca Clissa, Mario Lassnig, Lorenzo Rinaldi: *How big is big data? a comprehensive survey of data production, storage, and streaming in science and industry.* Big Data and AI in High Energy Physics, 6(9), 2023. https://www.frontiersin.org/journals/big-data/articles/10.3389/fdata.2023.1271639/full. 1, 2

[2] Begen, Ali C., Thomas Stockhammer, and Colin Perkins: *Energy and ai.* Technical report, INTERNATIONAL ENERGY AGENCY, 2025. https://www.iea.org/. 2

[3] Amaral, Dino Macedo: *Hy-SAIL: Uma nova abordagem para distribuição e armazenamento de informações em ambientes de computação em nuvem.* PhD thesis, Universidade de Brasília, 2013. 2

[4] Yu, Shui: *Big privacy: Challenges and opportunities of privacy study in the age of big data.* IEEE Access, 4:2751–2763, 2016. 3

[5] Zhao, Xiaoyan, Conghui Zhang, and Shaopeng Guan: *A data lake-based security transmission and storage scheme for streaming big data.* Cluster Computing, 27(4):4741–4755, Jul 2024, ISSN 1573-7543. https://doi.org/10.1007/s10586-023-04201-9. 3

[6] Hakami, Tahani Ali, Yasser M. Alginahi, and Omar Sabri: *Exploring the evolution of big data technologies: A systematic literature review of trends, challenges, and future directions.* Future Internet, 17(9), 2025, ISSN 1999-5903. https://www.mdpi.com/1999-5903/17/9/427. 3

[7] Villamar-Torres, Ronald Oswaldo, Verónica Cristina Andrade Yucailla, Karen Rafaela Mayorga Morejon, Héctor Adonis Almeida Reyes, and Seyed Mehdi Jazayeri: *An overview to the new era in efficient crop management: Artificial intelligence, machine learning, big data, bioinformatics, metagenomics and precision agriculture.* Journal of Animal and Plant Sciences, 35(3):638–659, June 2025, ISSN 1018-7081. https://thejaps.org.pk/AbstractView.aspx?mid=2024-japs-1928. 3